

Извлечение кортежей мнений из русскоязычных новостей: дообученная русскоязычная LLM против многоязычных решений

Грузин Н.А. Б13-303

Аннотация

Извлечение мнений из текста редко сводится к одному ярлыку тональности: чтобы сигнал был полезен, приходится знать, кто высказывается, о ком и какими именно словами. Мы решаем эту структурную постановку в формулировке соревнования RuOpinionNE-2024, где из новостного предложения требуется восстановить все кортежи (источник, объект, выражение, тональность). Сущности здесь почти всегда организации и персоны, поэтому извлечённый кортеж работает как entity-level сигнал тональности, востребованный в финансовом анализе новостного потока. Опираясь на русскоязычную модель T-pro-it-2.0 (Qwen3-32B) и дообучив её методом QLoRA с генерацией строгого JSON и последующей агрегацией нескольких сэмплов, мы получаем $F1 = 0.460$ на единственном публично размеченном наборе. На том же наборе это превосходит и лучшую систему фазы валидации (0.34), и базовое решение организаторов (0.17); полученное число выше и лучшего результата фазы теста (0.41, дообученная LLaMA-3.3-70B), хотя валидация и тест это разные сплиты, поэтому последнее сравнение прямым не является. Победитель шёл схожим путём, дообучая модель и агрегируя несколько ответов, так что наш интерес не в самой схеме, а в том, что русскоязычная модель вдвое меньшего размера её обходит. Код и все конфигурации эксперимента открыты.

1. Введение

Новостной поток остаётся одним из самых ранних источников информации о компаниях и рынках, и для прикладного анализа важна не усреднённая окраска заметки, а отношение к конкретному эмитенту: кто его высказал, к кому оно обращено и чем подкреплено. Обычная классификация тональности предложения такого ответа не даёт, теряя ровно ту структуру, ради которой текст и читают.

Восстанавливая эту структуру, задача structured sentiment analysis превращает предложение в набор кортежей мнений. Для русского языка её задаёт соревнование RuOpinionNE-2024 [1], продолжающее RuSentNE-2023 [2]. Поскольку размечены в этих новостях преимущественно организации и персоны, аккурратно извлечённый кортеж оказывается тем самым entity-level сигналом, что используется в финансовом NLP, но дополненным указанием источника оценки и её словесного обоснования.

Задача трудная: лучшее решение соревнования остановилось на 0.41 F1, базовое набрало 0.24 на тесте и 0.17 на валидации, так что запас для улучшения заведомо велик. Победитель добивался своего числа дообучением LLaMA-3.3-70B и агрегацией нескольких генераций, поэтому сама по себе схема, то есть дообучение плюс голосование, не нова. Наш вопрос ставится иначе: хватит ли русскоязычной T-pro-it-2.0 на базе Qwen3-32B, вдвое меньшей по числу параметров, чтобы под той же схемой получить более высокий результат. Как выясняется, хватает. Наш вклад:

- постановка задачи и разбор метрики, доведённый до краевых случаев разметки, на которых обычно и теряются баллы;
- дообученное QLoRA-решение на T-pro-it-2.0, превосходящее лучший опубликованный результат фазы валидации при вдвое меньшем размере модели;
- сравнение с конкурентами по единой метрике: та же модель без дообучения, вклад self-consistency и опубликованные участники;
- воспроизводимый пайплайн с открытым кодом, считающий качество официальным скриптом.

2. Обзор работ

Structured sentiment analysis. Извлечение кортежей мнений, восходящее к SemEval-2022 Task 10 [4], изначально ставилось как разметка графа, в котором узлами служат спаны источника, объекта и выражения, а рёбрами полярные связи между ними. Ранние системы, опираясь на разбор зависимостей и на энкодеры с CRF, строили этот граф напрямую. С приходом инструктивных LLM задачу всё чаще переформулируют как генерацию: модель печатает кортежи текстом, после чего спаны выравнивают по исходному предложению.

Целевая тональность для русского. RuSentNE-2023 [2] решал более узкую задачу, спрашивая лишь тональность предложения к заранее указанной сущности. В развивающей эту линию работе [3] дообученная Flan-T5-xl, рассуждавшая по схеме three-hop chain-of-thought (THoR), обошла лучший энкодерный результат соревнования, и здесь видна общая закономерность: рассуждение перед ответом помогает целевой тональности. RuOpinionNE-2024 [1], добавив извлечение источника и обоснования, поднимает планку до полного кортежа.

Результаты RuOpinionNE-2024. Обзор соревнования [1] приводит две таблицы. На фазе валидации лучшим оказался результат 0.34 F1 (Zholtikov_Michail), тогда как базовое решение, то есть Qwen2.5-32B в режиме 10-shot, дало лишь 0.17. На финальном тесте победила дообученная в 4-бит LLaMA-3.3-70B с агрегацией пяти ответов (VatolinAlexey, 0.41), за ней расположились 0.35, 0.33 и 0.28, а базовое решение набрало 0.24. Победитель, как видно, сделал ставку на крупную англоцентричную модель и на self-consistency; мы сохраняем идею агрегации, но меняем основу на русскоязычную модель меньшего размера.

LLM для русского. Линейка T-lite/T-pro [5], адаптирующая Qwen2.5/Qwen3 под русский переобучением токенизатора и продолженным предобучением, к 2025 году заметно подтянула качество на русскоязычных бенчмарках; построенная на Qwen3-32B модель T-pro-it-2.0 как раз из этого семейства. Чтобы уместить её 32 миллиарда параметров в 4-бит на одной A100, мы дообучаем её методом QLoRA [6], надстроенным над LoRA [7].

Финансовый NLP. Тональность в финансах традиционно снимали моделями уровня FinBERT [9], обученными на наборах вроде Financial PhraseBank [10]. Давая оценку всему сообщению целиком, такие модели не отвечают на вопрос, к кому именно она относится. Извлечение кортежей мнений этот пробел закрывает, сразу указывая объект оценки и её обоснование, то есть именно ту информацию, которой пословная классификация не даёт.

Self-consistency. Голосование по нескольким сэмплам генерации [8], предложенное изначально для арифметических рассуждений, мы переносим на извлечение: кортеж принимается, если он встретился не менее чем в k из N независимых генераций. Снижая разброс, такая агрегация заодно отсекает редкие галлюцинации.

3. Данные и постановка задачи

Формат. На входе подаётся предложение из новостного текста, на выходе ожидается множество кортежей мнений, каждый из которых состоит из четырёх частей. Источником мнения выступает либо именованная сущность, либо специальная метка AUTHOR (когда оценку высказывает автор текста), либо NULL (когда источник не выражен); объектом служит сущность; выражение это один или несколько фрагментов, обосновывающих оценку; тональность принимает значения POS или NEG. Источник, объект и выражение задаются точными подстроками предложения с символьными смещениями.

Объём и распределение. Статистика наборов сведена в таблицу 1, и в ней обращают на себя внимание две особенности. Во-первых, около 41% предложений вовсе не содержат мнений, а значит, модель обязана уметь возвращать пустой ответ, иначе страдает точность. Во-вторых, число кортежей на предложение распределено длиннохвосто: чаще всего их ноль, один или два, но попадаются предложения и с десятком, и даже с двадцатью тремя кортежами. По типу источника преобладает именованная сущность, заметную долю составляют мнения без выраженного источника (NULL), и примерно четырнадцать процентов исходят от автора. Отдельную трудность создают разрывные выражения, обоснование в которых собрано из несоседних фрагментов (например, "снял ... ограничения на реализацию"). Утечки между обучением и валидацией нет: ни одно из 1316 валидационных предложений в обучающей части не встречается, что мы проверили явно.

Таблица 1: Статистика RuOpinionNE-2024.

	Train	Validation	Test
Предложений	2556	1316	803
из них без мнений	1062	547	n/a
Кортежей	2904	1612	скрыто
POS/NEG	1174/1730	753/859	n/a
Источник entity/null/author	1623/897/384	980/436/196	n/a
Разрывных выражений	19	6	n/a

Метрика. Качество измеряется взвешенным tuple-F1 (официальный скрипт соревнования). Предсказанный кортеж засчитывается совпавшим с эталонным тогда, когда источник, объект и выражение пересекаются по токенам хотя бы на один токен, а тональность совпадает точно. Поскольку вклад совпадения взвешивается средней долей пересечения по трём спанам, частичные попадания учитываются мягко, не обнуляясь. Точность и полнота считаются по всему набору и затем сводятся в F1, причём метка NULL в роли источника трактуется отдельно от AUTHOR.

Протокол оценки. Соревнование на CodaLab закрыто, а разметка теста не опубликована, поэтому единственным публично размеченным набором остаётся валидация. Обучаясь только на обучающей части и оценивая результат на валидации официальным скриптом, мы получаем число, прямо сопоставимое с таблицей фазы валидации (лучшая система 0.34, базовое решение 0.17). Числа фазы теста мы приводим для полноты, оговаривая, что шкалы фаз заметно различаются.

Финансовая привязка. Сущности набора это в основном компании, банки, регуляторы и должностные лица, а извлечённый кортеж (источник, объект, выражение, тональность) и есть entity-level новостной сигнал, отвечающий, к какому эмитенту относится оценка, кто её высказал и чем она обоснована. В отличие от пословной тональности, такой сигнал можно агрегировать по конкретной компании во времени.

4. Подход

Постановка как генерация. Формулируя извлечение как инструктивную генерацию, мы описываем в системном промпте определение кортежа и требуем на выходе строгий JSON-массив объектов с полями `holder`, `target`, `expression` (список фрагментов) и `polarity`. Печатая подстроки исходного предложения, модель не выдаёт смещения напрямую, поэтому символьные позиции мы восстанавливаем поиском подстроки и приводим к официальному формату. Корректность этого преобразования подтверждена round-trip тестом: эталон, прогнанный через сериализацию, парсинг и обратное восстановление смещений, даёт $F1 = 0.999$, а значит, формат и парсер информацию практически не теряют.

Санитизация. Официальный скрипт прерывается с ошибкой, если в одном предложении два кортежа делят источник, объект и тональность при пересекающихся выражениях. Чтобы предсказание оставалось валидным при любом выходе модели, мы пропускаем его через дедупликацию, повторяющую логику официального конвертера, но отбрасывающую конфликтный кортеж вместо того, чтобы упасть.

Основная модель. Дообучая T-pro-it-2.0 (Qwen3-32B) методом QLoRA, мы держим базовые веса в 4-бит (nf4, double quantization, вычисления в bfloat16) и обучаем LoRA-адаптеры на всех линейных проекциях (ранг 32, $\alpha = 64$, dropout 0.05). Лосс считается только по токенам ответа, тогда как промпт маскируется. Оптимизация ведётся paged AdamW 8-bit при learning rate 10^{-4} с косинусным спадом и прогревом в 5%; обучение длится три эпохи при эффективном батче 16 и ограничении длины в 2048 токенов, с включённым gradient checkpointing. Режим рассуждения отключён намеренно: печатая JSON сразу, модель экономит токены и время инференса.

Self-consistency. На инференсе мы порождаем N независимых сэмплов при ненулевой температуре и сводим их голосованием, принимая кортеж, если он встретился не менее чем в k из N ответов; порог k подбирается по валидации. При $N = 1$ это вырождается в обычное жадное декодирование, тогда как голосование, снижая разброс на небольшом наборе, убирает редкие нестабильные кортежи.

Конкурентные подходы. Сравнение мы ведём по трём осям. Первая это та же T-pro-it-2.0 без дообучения, в режимах zero-shot и few-shot, позволяющая отделить вклад дообучения от качества самой модели. Вторая это вклад self-consistency, измеряемый сопоставлением жадного декодирования с агрегацией сэмплов. Третья это опубликованные результаты участников, включая решение-победитель на LLaMA-3.3-70B. Так как все наши числа посчитаны одним официальным скриптом на одном наборе, сравнение остаётся прямым.

5. Эксперименты и результаты

Окружение. Все запуски выполнены на одной NVIDIA A100 80GB; инференс вёлся через vLLM с загрузкой базовой модели в 4-бит, а качество измерялось официальным скриптом RuOpinionNE-2024 на валидационном наборе.

Для полноты приведём числа фазы теста [1]: победитель (LLaMA-3.3-70B с агрегацией) набрал 0.41, далее идут 0.35 и 0.33, а базовое решение 0.24. Так как шкалы валидации и теста различаются, основное сопоставление мы ведём на валидации, где наш результат 0.460 превосходит и лучшую валидационную систему (0.34), и лучший тестовый результат (0.41).

Вклад дообучения. Без дообучения T-pro набирает всего 0.191 в zero-shot и 0.199 в few-shot: правильную JSON-структуру модель печатает, однако границы

Таблица 2: Результаты на валидационном наборе RuOpinionNE-2024 (взвешенный tuple-F1). Числа предыдущих работ взяты из обзора соревнования [1].

Система	Размер	F1 (валидация)
Базовое решение (Qwen2.5-32B, 10-shot) [1]	32B	0.17
Лучшая система фазы валидации [1]	n/a	0.34
T-pro-it-2.0, zero-shot (наша)	32B	0.191
T-pro-it-2.0, few-shot 3 (наша)	32B	0.199
T-pro-it-2.0 + QLoRA, жадное декодирование (наша)	32B	0.438
T-pro-it-2.0 + QLoRA + self-consistency (наша)	32B	0.460

спанов угадывает плохо и часть мнений упускает. Примеры в контексте почти не выручают, и это объяснимо, ведь задача упирается не в формат, а в точное выделение источника, объекта и выражения. Дообучение же поднимает результат до 0.438, из чего следует, что основной прирост даёт адаптация под конкретную разметку, а не размер модели и не few-shot.

Выбор эпохи. Сохраняя адаптер после каждой эпохи, мы оценили все три (таблица 3). Прирост между второй и третьей эпохами невелик, а переобучения на валидации не наблюдается, поэтому в качестве рабочей мы берём третью.

Таблица 3: F1 по эпохам (жадное декодирование).

Эпоха	1	2	3
F1	0.395	0.435	0.438

Self-consistency. Порождая пять сэмплов при температуре 0.6, мы принимаем кортеж по порогу k из пяти, и этот порог регулирует баланс полноты и точности. При $k = 1$ берётся объединение всех сэмплов ($F1 = 0.435$), при $k = 5$ остаётся их пересечение (0.299), а оптимум достигается на $k = 2$, давая 0.460 и прибавляя 0.022 к жадному декодированию. Отбрасывая нестабильные кортежи, голосование при чрезмерно высоком пороге начинает терять и верные, чем и объясняется спад на $k \geq 3$.

Анализ ошибок. На лучшем прогоне модель нашла 737 кортежей при 871 пропуске и 750 ложных срабатываниях, так что основная потеря приходится на полноту: распознаётся примерно половина эталонных кортежей. Тональность при этом почти не путается (всего шесть случаев, когда спаны совпали, а знак нет), а значит, найдя кортеж, модель определяет его полярность надёжно. Тяжелее всего даются мнения без явного источника (NULL), где доля пропусков максимальна; разрывные же выражения, будучи редкими, на итог почти не влияют. Главным резервом роста остаётся полнота на неявно выраженных мнениях.

6. Заключение

Решая задачу извлечения кортежей мнений из русских новостей, мы получили на единственном публично размеченном наборе $F1 = 0.460$, что выше и лучшей валидационной системы соревнования (0.34), и базового решения (0.17). Это число превосходит и лучший результат фазы теста (0.41), но валидация и тест это разные сплиты, поэтому последнее сопоставление остаётся косвенным. Определяющим оказался выбор основы: при той же схеме из дообучения и self-consistency русскоязычная T-pro-it-2.0 на 32 миллиарда параметров дала более высокий результат, чем англоцентричная LLaMA-3.3-70B победителя, будучи вдвое меньше. В приложении к финансам извлечённые кортежи дают entity-level сигнал тональности к компаниям, пригодный для агрегации новостного фона по отдельному эмитенту, а основным направлением дальнейшей работы видится повышение полноты на мнениях без явного источника.

Список литературы

- [1] Lukashevich N., Rusnachenko N. et al. RuOpinionNE-2024: Extraction of Opinion Tuples from Russian News Texts. arXiv:2504.06947, 2025.
- [2] Golubev A., Rusnachenko N., Loukachevitch N. RuSentNE-2023: Named Entity Oriented Sentiment Analysis. arXiv:2305.17679, 2023.
- [3] Rusnachenko N., Loukachevitch N. Large Language Models in Targeted Sentiment Analysis for Russian. arXiv:2404.12342, 2024.
- [4] Barnes J. et al. SemEval-2022 Task 10: Structured Sentiment Analysis. SemEval, 2022.
- [5] T-Tech. T-pro-it-2.0 (Qwen3-32B, russian-adapted). Hugging Face, 2025.
- [6] Detrmers T. et al. QLoRA: Efficient Finetuning of Quantized LLMs. arXiv:2305.14314, 2023.
- [7] Hu E. et al. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685, 2021.
- [8] Wang X. et al. Self-Consistency Improves Chain of Thought Reasoning. arXiv:2203.11171, 2022.
- [9] Araci D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. arXiv:1908.10063, 2019.
- [10] Malo P. et al. Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. JASIST, 2014.